

INTRODUCERE

Acest proiect urmărește analiza activității lunare a locației turistice Casa Timiș, pe o perioadă de trei ani, folosind două instrumente complementare: Python (prin dezvoltarea unei aplicații interactive în Streamlit) și SAS (pentru prelucrarea și analiza detaliată a datelor).

Scopul este de a înțelege mai bine evoluția veniturilor, a numărului de oaspeți și a nivelului de satisfacție al clienților, dar și de a identifica tendințe, sezonabilitate și factorii care influențează performanța lunară.

Partea realizată în Python a inclus dezvoltarea unei aplicații ușor de utilizat, care permite explorarea vizuală a datelor, tratarea valorilor lipsă și extreme, codificarea și scalarea variabilelor, segmentarea lunilor pe baza performanței și testarea unor modele predictive.

În completare, analiza realizată în SAS a vizat importul datelor, curățarea și transformarea acestora, utilizarea procedurilor statistice, crearea de subseturi și aplicarea unor modele de regresie. Accentul a fost pus pe interpretarea economică a rezultatelor și pe extragerea unor concluzii utile pentru luarea deciziilor.

Prin combinarea celor două abordări – una mai vizuală și orientată pe machine learning, cealaltă mai riguroasă și statistică – proiectul oferă o perspectivă completă asupra activității de la Casa Timiș și propune soluții concrete pentru optimizarea performanței în domeniul ospitalității.

PROGRAMARE PYTHON

1. Utilizarea metodelor *Streamlit* pentru afișare, reprezentări grafice etc.

a) Definirea problemei

Pentru a analiza mai ușor activitatea lunară și recenziile clienților de la Casa Timiș, am considerat că e utilă o interfață vizuală, interactivă. Ne-am dorit să construim o aplicație ușor de folosit, chiar și pentru persoane care nu au cunoștințe tehnice, astfel încât să poată urmări datele și trage concluzii relevante.

b) Informații necesare pentru rezolvare

Datele de intrare sunt două fișiere CSV ce conțin informații despre activitatea lunară (număr de oaspeți, venituri, rată de ocupare etc.) și recenziile clienților. Pentru partea de afișare, am folosit biblioteca *streamlit* (prescurtat *st*), care ne-a permis să dezvoltăm o aplicație web.

c) Metode de calcul, algoritmi, formule utilizate

Aplicația folosește funcțiile *st.image*, *st.title*, *st.subheader*, *st.dataframe*, *st.map*, *st.bar_chart*, *st.line_chart*, *st.write*, *st.success*, *st.warning*, *st.info*, toate parte din pachetul *Streamlit*.

Acestea ne-au ajutat să prezentăm datele sub formă de tabele interactive și grafice.

d) Prezentarea rezultatelor

Datele sunt prezentate în tabele interactive, grafice, precum și prin mesaje descriptive. Astfel, utilizatorul poate observa ușor evoluțiile și eventualele probleme identificate în date.

	Month_Year	Number_of_Guests	Occupancy_Rate_%	Average_Room_Price_EUR	Spa_Revenue_EUR
0	January 2022	313	87.67	156.98	10516.5
1	February 2022	2500	60.69	206.78	14484.5
2	March 2022	299	37.77	304.5	14502.5
3	April 2022	325	76.36	315.18	13036.5
4	May 2022	340	79.45	101.74	6354.5
5	June 2022	301	66.48	227.69	17529.5
6	July 2022	309	80.11	204.35	Noi
7	August 2022	316	62.1	155.53	Noi

	Month_Year	Average_Review_Score	Number_of_Reviews	Percentage_Positive_Reviews	Complaints
0	January 2022	9.15	42	94.88	
1	February 2022	8.99	45	87.44	
2	March 2022	None	51	86.06	
3	April 2022	9.44	49	94.64	
4	May 2022	8.56	55	85.4	
5	June 2022	None	42	93.79	
6	July 2022	9.29	46	99.1	
7	August 2022	8.35	44	93.63	

e) Interpretarea economică a rezultatelor

Interfața vizuală ajută managerii și analiștii să identifice rapid tendințe precum creșterea numărului de oaspeți sau a veniturilor, sezonalițăți sau scăderi ale satisfacției clienților. Acest lucru contribuie la luarea deciziilor operaționale și strategice bazate pe date.

2. Utilizarea pachetului *Geopandas*

a) Definirea problemei

Pentru a oferi un context geografic analizei, am inclus afișarea pe hartă a locației Casa Timiș. Această reprezentare ajută la înțelegerea mai clară a poziționării spațiale și poate fi utilă în evaluarea accesibilității și a atractivității zonei pentru clienți.

b) Informații necesare pentru rezolvare

Este necesară cunoașterea coordonatelor GPS ale locației (latitudine și longitudine).


Se utilizează pachetul *geopandas* (prescurtat *gpd*) pentru a crea un *GeoDataFrame* și funcția *st.map* din *Streamlit* pentru a-l afișa pe hartă.

c) Metode de calcul, algoritmi, formule utilizate

Se creează un GeoDataFrame folosind funcția *points_from_xy* cu coordonatele longitudine și latitudine. Acest GeoDataFrame este convertit într-un format acceptat de *st.map* pentru a putea fi reprezentat vizual.

d) Prezentarea rezultatelor

Aplicația afișează harta cu punctul geografic al locației Casa Timiș. Acesta este vizibil pe o hartă interactivă direct în aplicația Streamlit.



e) Interpretarea economică a rezultatelor

Vizualizarea locației poate influența deciziile privind campanii de promovare, planificarea transportului sau extinderea serviciilor. De asemenea, ajută clienții să localizeze mai ușor locația și să își planifice vizitele.

3. Tratarea valorilor lipsă

a) Definirea problemei

Valorile lipsă din seturile de date pot distorsiona rezultatele analizelor și pot compromite validitatea modelelor predictive. Este esențială detectarea și completarea acestora pentru a asigura calitatea analizei.

b) Informații necesare pentru rezolvare

Se folosesc funcțiile *isna()* și *sum()* din pandas pentru a detecta valorile lipsă. Se aplică completarea cu mediana pentru valorile numerice și cu moda pentru cele categorice.

c) Metode de calcul, algoritmi, formule utilizate

Se aplică o funcție personalizată care parcurge fiecare coloană și în funcție de tipul de date, aplică *fillna()* cu mediana sau moda.

d) Prezentarea rezultatelor

În aplicație se afișează un mesaj care indică dacă s-au găsit sau nu valori lipsă. Valorile lipsă sunt înlocuite și apoi datele sunt afișate din nou pentru validare.

 **Complete check for missing values**

✖ Missing values detected:

Activity Data:

Column	Missing Values
Spa_Revenue_EUR	4

Reviews Data:

Column	Missing Values
Average_Review_Score	3

✔ All missing values have been successfully handled.

	Month_Year	Number_of_Guests	Occupancy_Rate_%	Average_Room_Price_EUR	Spa_Revenue_EUR
0	January 2022	313	87.67	156.98	10516.5
1	February 2022	2500	60.69	206.78	14484.5
2	March 2022	299	37.77	304.5	14502.5
3	April 2022	325	76.36	315.18	13036.5
4	May 2022	340	79.45	101.74	6354.5
5	June 2022	301	66.48	227.69	17529.5
6	July 2022	309	80.11	204.35	12990.5
7	August 2022	316	62.1	155.53	12990.5
8	September 2022	2500	63.98	129.97	5611.5
9	October 2022	309	57.79	184.4	13863.5



Data after cleaning - Customer Reviews

	Month_Year	Average_Review_Score	Number_of_Reviews	Percentage_Positive_Reviews	Complair
0	January 2022	9.15	42	94.88	
1	February 2022	8.99	45	87.44	
2	March 2022	9.29	51	86.06	
3	April 2022	9.44	49	94.64	
4	May 2022	8.56	55	85.4	
5	June 2022	9.29	42	93.79	
6	July 2022	9.29	46	99.1	
7	August 2022	8.35	44	93.63	
8	September 2022	9.88	41	90.82	
9	October 2022	9.91	25	94.65	

e) Interpretarea economică a rezultatelor

Completarea valorilor lipsă permite o analiză continuă, evitând pierderea de informații.

Asigură claritatea datelor și permite utilizarea completă a dataset-urilor în modelele statistice și predictive.

4. Tratarea valorilor extreme

a) Definirea problemei

Valorile extreme (outliers) pot distorsiona media și pot afecta semnificativ rezultatele analizelor statistice și ale modelelor predictive. În cazul nostru, numărul foarte mare de oaspeți într-o lună poate fi un astfel de exemplu.

b) Informații necesare pentru rezolvare

Datele privind *Number_of_Guests* sunt analizate pentru a detecta valori care depășesc un prag considerat nenatural (ex. 1500). Se utilizează *pandas* pentru filtrare și înlocuire.

c) Metode de calcul, algoritmi, formule utilizate

Se filtrează datele cu valori mai mari decât pragul și se înlocuiesc cu valoarea medianei calculate pentru valorile normale. Se folosește *.median()* și condiționare prin *.loc[]*.

d) Prezentarea rezultatelor

Aplicația afișează numărul de outliers detectați, valorile acestora și confirmă înlocuirea cu valoarea mediană.

Outlier check for number of guests

⚠ 4 outlier(s) detected in Number_of_Guests (value > 1500):

	Month_Year	Number_of_Guests
1	February 2022	2500
8	September 2022	2500
15	April 2023	2500
34	November 2024	2500

✅ Replaced 4 extreme values with the median: 313.5

e) Interpretarea economică a rezultatelor

Această corecție menține coerența setului de date și asigură că valorile extreme nu influențează eronat deciziile manageriale sau predicțiile financiare.

5. Codificarea datelor (OneHotEncoder)

a) Definirea problemei

Datele de tip text (categorice), cum ar fi lunile anului, nu pot fi procesate direct de modelele matematice și trebuie transformate într-o formă numerică prin codificare.

b) Informații necesare pentru rezolvare

Este necesară extragerea lunii din coloana *Month_Year* și codificarea acesteia folosind OneHotEncoder din *sklearn.preprocessing*.

c) Metode de calcul, algoritmi, formule utilizate

Se aplică OneHotEncoding, generând o coloană binară pentru fiecare lună, ceea ce permite includerea lunilor ca variabile explicative în modele.

d) Prezentarea rezultatelor

Datele codificate sunt afișate sub forma unui nou DataFrame, cu o coloană pentru fiecare lună, populată cu valori 0 sau 1.

1 Encoded Month Data

	Month_April	Month_August	Month_December	Month_February	Month_January	Month_July	Mon
0	0	0	0	0	1	0	
1	0	0	0	1	0	0	
2	0	0	0	0	0	0	
3	1	0	0	0	0	0	
4	0	0	0	0	0	0	
5	0	0	0	0	0	0	
6	0	0	0	0	0	1	
7	0	1	0	0	0	0	
8	0	0	0	0	0	0	
9	0	0	0	0	0	0	

e) Interpretarea economică a rezultatelor

Codificarea lunilor permite detectarea sezonalițăților și includerea acestora în modele predictive sau analize economice.

6. Scalarea datelor

a) Definirea problemei

Diferențele mari de scară între variabile numerice (ex: venituri vs. rată de ocupare) pot afecta performanța modelelor de învățare automată. Este necesară aducerea acestora pe aceeași scară.

b) Informații necesare pentru rezolvare

Se selectează coloanele numerice relevante: *Number_of_Guests*, *Occupancy_Rate_Percent*, *Average_Room_Price_EUR*. Se folosește *StandardScaler* din *sklearn*.

c) Metode de calcul, algoritmi, formule utilizate

Scalarea se face prin standardizare: scăderea mediei și împărțirea la deviație standard, rezultând variabile cu medie 0 și deviație standard 1.

d) Prezentarea rezultatelor

Valorile scalate sunt afișate în aplicație pentru verificare, și sunt folosite ulterior în modele statistice și predictive.



Scaled Numerical Data

	Number_of_Guests	Occupancy_Rate_%	Average_Room_Price_EUR
0	-0.214	1.3034	-0.841
1	-0.1821	-0.1171	-0.1519
2	-1.1052	-1.3237	1.2001
3	0.5499	0.7079	1.3479
4	1.5048	0.8706	-1.6053
5	-0.9779	0.1878	0.1374
6	-0.4686	0.9053	-0.1856
7	-0.023	-0.0428	-0.861
8	-0.1821	0.0562	-1.2147
9	-0.4686	-0.2697	-0.4616

e) Interpretarea economică a rezultatelor

Permite compararea directă între variabile diferite și previne influențarea nedorită a modelelor de către variabile cu valori mai mari.

7. Prelucrări statistice și grupare în *pandas*

a) Definirea problemei

Este necesară analiza evoluției veniturilor și a numărului de oaspeți pe ani pentru a identifica trenduri și sezonaliități.

b) Informații necesare pentru rezolvare



Coloanele *Year*, *Total_Revenue_EUR*, *Number_of_Guests* sunt esențiale. Se folosește funcția *groupby()* din *pandas* pentru a agrega valorile pe ani.

c) Metode de calcul, algoritmi, formule utilizate

Se aplică agregarea prin *mean()* după *groupby('Year')* și se afișează grafice de tip bară și linie cu *st.bar_chart()* și *st.line_chart()*.

d) Prezentarea rezultatelor

Se afișează grafic evoluția veniturilor și a numărului mediu de oaspeți pentru fiecare an. Aceste grafice sunt interactive.



e) Interpretarea economică a rezultatelor

Permite identificarea performanțelor financiare și a popularității locației de-a lungul anilor. Se pot lua decizii strategice pe baza acestor date.

8. Utilizarea *scikit-learn*: Clusterizare și regresie logistică

a) Definirea problemei

Se dorește segmentarea lunilor în grupuri de performanță și construirea unui model de clasificare care să prezică grupul din care face parte o lună nouă.

b) Informații necesare pentru rezolvare

Coloanele *Total_Revenue_EUR* și *Number_of_Guests* sunt folosite pentru clustering și regresie logistică. Se utilizează *KMeans* și *LogisticRegression*.

c) Metode de calcul, algoritmi, formule utilizate

Se aplică algoritmul *KMeans* cu 3 clustere. Apoi se construiește un model de clasificare folosind *LogisticRegression*, iar datele sunt împărțite în seturi de antrenare și test.

d) Prezentarea rezultatelor

Sunt afișate clusterile lunilor și performanța modelului de regresie logistică prin acuratețe și raport de clasificare.



Cluster Assignments

	Month_Year	Cluster
0	January 2022	1
1	February 2022	0
2	March 2022	2
3	April 2022	2
4	May 2022	1
5	June 2022	0
6	July 2022	1
7	August 2022	1
8	September 2022	1
9	October 2022	1

Logistic Regression Model Evaluation

Accuracy: 0.75

Detailed Classification Report:



	precision	recall	f1-score	support
0	0	0	0	2
1	0.5	1	0.67	2
2	1	1	1	4
accuracy	0.75	0.75	0.75	0.75
macro avg	0.5	0.67	0.56	8
weighted avg	0.62	0.75	0.67	8

e) Interpretarea economică a rezultatelor

Clusterizarea permite identificarea lunilor de vârf și a celor slabe. Modelul ajută la prezicerea performanței lunilor viitoare, sprijinind planificarea afacerii.

9. Utilizarea *statsmodels*: Regresie multiplă

a) Definirea problemei

Se dorește estimarea veniturilor totale pe baza a doi factori: numărul de oaspeți și rata de ocupare.

b) Informații necesare pentru rezolvare

Coloanele *Total_Revenue_EUR*, *Number_of_Guests* și *Occupancy_Rate_Percent*. Se folosește *OLS()* din *statsmodels.api*.

c) Metode de calcul, algoritmi, formule utilizate

Se aplică regresie liniară multiplă, incluzând o constantă (intercept). Se obțin coeficienții și statistici de semnificație.

d) Prezentarea rezultatelor

Sunt afișate tabele cu coeficienții estimați, erorile standard, valorile t și p, precum și indicatori de performanță precum R^2 .

 Regression Analysis						
Multiple Regresson Summary						
	Coefficient	Standard Error	t-statistic	P> t	2.5% Interval	97.5% Interval
const	106731.719	4537.302	23.523	0	97500.509	115962.928
Number_of_Guests	-1864.473	4572.487	-0.408	0.686	-11167.268	7438.322
Occupancy_Rate_%	1246.576	4572.487	0.273	0.787	-8056.22	10549.371
Additional Model Statistics						
	Statistic		Value			
0	R-squared		0.007			
1	Adj. R-squared		-0.054			
2	F-statistic		0.108			
3	Prob (F-statistic)		0.898			

e) Interpretarea economică a rezultatelor

Modelul evidențiază impactul fiecărui factor asupra veniturilor. Poate fi folosit pentru a estima veniturile viitoare și pentru a identifica cele mai influente variabile în creșterea financiară.

Concluzie

Proiectul realizat în Python, cu ajutorul aplicației construite în Streamlit, a arătat cât de utilă poate fi o abordare interactivă și ușor de folosit în analiza datelor. Aplicația ne-a permis să vizualizăm informațiile, să curățăm și să pregătim datele, să le codificăm și să le scalăm, dar și să aplicăm modele predictive simple.

Cu ajutorul bibliotecilor Pandas, scikit-learn, statsmodels și geopandas, am putut lucra eficient cu datele și am creat o aplicație care ajută la înțelegerea activității lunare de la Casa Timiș. Graficele, hărțile și tabelele interactive fac informațiile mai ușor de interpretat.

Chiar dacă unele modele nu au avut o precizie mare, analiza a scos la iveală legături utile între indicatorii economici și a ajutat la gruparea lunilor în funcție de performanță. În final, aplicația oferă un sprijin real în luarea deciziilor legate de sezonabilitate, venituri și comportamentul clienților, fiind un instrument practic și accesibil pentru Casa Timiș.

PROGRAMARE SAS

1. Importul fișierelor CSV

a) Definirea problemei:

Pentru a putea efectua analize statistice și economice în SAS, este necesar să importăm datele brute din fișiere externe (CSV) în mediul SAS.

b) Informații necesare pentru rezolvare:

Este necesar să cunoaștem locația fișierelor CSV, structura acestora (numele coloanelor, formatul valorilor) și să folosim procedura adecvată pentru import în SAS.

c) Metode de calcul, algoritmi, formule de calcul utilizate:

Datele au fost importate în SAS folosind procedura *PROC IMPORT*, specificând tipul fișierului prin opțiunea *DBMS=csv*, care indică faptul că sursa este un fișier CSV. Opțiunea *REPLACE* asigură suprascrierea automată a setului de date dacă acesta există deja în biblioteca *WORK*. *GETNAMES=YES* permite recunoașterea primei linii din fișier ca nume de variabile (headere).

Această procedură a fost aplicată separat pentru fișierele:

- *Casa_Timis_Monthly_Activity_3Y.csv* → setul de date *activity*

Total rows: 36 Total columns: 7

Rows

	Month_Year	Number_of_Guests	Occupancy_Rate_Percent	Average_Room_Price_EUR	Spa_Revenue_EUR	Restaurant_Revenue_EUR	Total_Revenue_EUR
1	January 2022	313	87.67	156.98	10516.75	31778.67	91430.16
2	February 2022	2500	60.69	206.78	14484.59	36913.31	120255.64
3	March 2022	299	37.77	304.5	14502.95	36612.59	142161.04
4	April 2022	325	76.36	315.18	13036.62	33396.27	148866.39
5	May 2022	340	79.45	101.74	6354.35	29260.95	70206.9
6	June 2022	301	66.48	227.69	17529.54	12524.2	98588.43
7	July 2022	309	80.11	204.35	.	14848.86	87804.71

- *Casa_Timis_Customer_Reviews_3Y.csv* → setul de date *reviews*

Total rows: 36 Total columns: 5

	Month_Year	Average_Review_Score	Number_of_Reviews	Percentage_Positive_Reviews	Complaints_Count
1	January 2022	9.15	42	94.88	6
2	February 2022	8.99	45	87.44	5
3	March 2022	.	51	86.06	5
4	April 2022	9.44	49	94.64	0
5	May 2022	8.56	55	85.4	2
6	June 2022	.	42	93.79	5

d) Prezentarea rezultatelor:

Ca urmare a rulării *PROC IMPORT*, două seturi de date (*activity* și *reviews*) au fost create în biblioteca temporară *WORK*, fiind disponibile pentru prelucrări ulterioare. Conținutul acestora a fost verificat folosind *PROC CONTENTS*.

Alphabetic List of Variables and Attributes					
#	Variable	Type	Len	Format	Informat
4	Average_Room_Price_EUR	Num	8	BEST12.	BEST32.
1	Month_Year	Char	14	\$14.	\$14.
2	Number_of_Guests	Num	8	BEST12.	BEST32.
3	Occupancy_Rate_Percent	Num	8	BEST12.	BEST32.
6	Restaurant_Revenue_EUR	Num	8	BEST12.	BEST32.
5	Spa_Revenue_EUR	Num	8	BEST12.	BEST32.
7	Total_Revenue_EUR	Num	8	BEST12.	BEST32.

Alphabetic List of Variables and Attributes					
#	Variable	Type	Len	Format	Informat
2	Average_Review_Score	Num	8	BEST12.	BEST32.
5	Complaints_Count	Num	8	BEST12.	BEST32.
1	Month_Year	Char	14	\$14.	\$14.
3	Number_of_Reviews	Num	8	BEST12.	BEST32.
4	Percentage_Positive_Reviews	Num	8	BEST12.	BEST32.

e) Interpretarea economică a rezultatelor:

Importarea corectă a datelor este un pas esențial, deoarece stă la baza întregii analize. Informațiile despre activitatea lunară și părerile clienților oferă o imagine clară asupra performanței afacerii, fiind extrem de utile pentru a lua decizii strategice bine informate în domeniul ospitalității.

2. Crearea și folosirea de formate definite de utilizator

a) Definirea problemei:

Variabilele continue (scoruri de review și număr de oaspeți) sunt dificil de interpretat direct. Este necesară gruparea lor în categorii semnificative pentru a facilita analiza și vizualizarea tendințelor.

b) Informații necesare pentru rezolvare:

- *Average_Review_Score* – scorul mediu de review (ex: 7.8, 8.6, 9.2)
- *Number_of_Guests* – numărul total de oaspeți într-o lună

c) Metode de calcul, algoritmi, formule de calcul utilizate:

Au fost definite formate personalizate prin *PROC FORMAT*, care clasifică valorile continue în intervale relevante (ex: Low, Medium, High). Formatele sunt aplicate apoi în pasul *DATA* folosind instrucțiunea *FORMAT*.

d) Prezentarea rezultatelor:

Noile variabile categorice (*score_fmt.*, *guests_fmt.*) sunt atașate în seturile *reviews_fmt* și *activity_fmt*.

	Month_Year	Complaint_Level
1	January 2022	High
2	February 2022	High
3	March 2022	High
4	April 2022	None
5	May 2022	Low

	Month_Year	Occupancy_Level
1	January 2022	High
2	February 2022	Medium
3	March 2022	Low
4	April 2022	Medium

e) Interpretarea economică a rezultatelor:

Aceste clasificări oferă o vedere de ansamblu clară asupra comportamentului clienților și volumului de activitate, permițând o segmentare eficientă în funcție de gradul de satisfacție și de intensitatea cererii.

3. Procesarea iterativă și condițională a datelor

a) Definirea problemei:

Este necesară crearea unor noi variabile descriptive care să reflecte în mod explicit anumite caracteristici calitative, precum severitatea reclamațiilor sau nivelul ocupării.

b) Informații necesare pentru rezolvare:

- *Complaints_Count* – numărul de reclamații într-o lună
- *Occupancy_Rate_Percent* – rata de ocupare exprimată procentual

c) Metode de calcul, algoritmi, formule de calcul utilizate:

S-au utilizat structuri *IF-THEN-ELSE* pentru a clasifica observațiile în categorii (*Complaint_Level*, *Occupancy_Level*). Lungimea variabilelor text a fost gestionată cu *LENGTH*. Prelucrarea s-a făcut în cadrul unui *DATA STEP*.

d) Prezentarea rezultatelor:

Două noi coloane de tip text au fost adăugate în seturile *complaints_flag* și *high_occupancy_flag*, indicând categoria fiecărei observații.

e) Interpretarea economică a rezultatelor:

Aceste clasificări permit detectarea automată a lunilor cu probleme sau performanțe notabile, facilitând prioritizarea intervențiilor manageriale.

4. Crearea de subseturi de date

a) Definirea problemei:

În vederea analizării specifice a anumitor situații, este necesară extragerea unor subseturi de date pe baza unor criterii relevante.

b) Informații necesare pentru rezolvare:

- *Average_Review_Score* – pentru identificarea review-urilor sub așteptări
- *Total_Revenue_EUR* – pentru identificarea lunilor cu venit scăzut

c) Metode de calcul, algoritmi, formule de calcul utilizate:

S-au utilizat expresii logice în cadrul *IF* în pasul *DATA* pentru a filtra observațiile care corespund criteriilor specificate.

d) Prezentarea rezultatelor:

Două seturi de date noi au fost create:

- *low_scores* (scoruri sub 9)

	Month_Year	Average_Review_Score	Number_of_Reviews	Percentage_Positive_Reviews	Complaints_Count
1	February 2022	8.99	45	87.44	5
2	March 2022	.	51	86.06	5
3	May 2022	8.56	55	85.4	2
4	June 2022	.	42	93.79	5
5	August 2022	8.35	44	93.63	1
6	December 2022	8.74	36	93.18	2
7	January 2023	8.03	51	99.12	2

- *low_revenue* (venituri sub 100000 EUR)

	Month_Year	Number_of_Guests	Occupancy_Rate_Percent	Average_Room_Price_EUR	Spa_Revenue_EUR	Restaurant_Revenue_EUR	Total_Revenue_EUR
1	January 2022	313	87.67	156.98	10516.75	31778.67	91430.16
2	May 2022	340	79.45	101.74	6354.35	29260.95	70206.9
3	June 2022	301	66.48	227.69	17529.54	12524.2	98588.43
4	July 2022	309	80.11	204.35	.	14848.86	87804.71
5	August 2022	316	62.1	155.53	.	36956.63	93901.89
6	September 2022	2500	63.98	129.97	5611.63	28192.87	76174.72
7	October 2022	309	57.79	184.4	13863.39	10275.91	81118.9

e) Interpretarea economică a rezultatelor:

Aceste subseturi permit concentrarea analizei asupra segmentelor problematice, oferind o bază pentru măsuri corective și planificare strategică.

5. Utilizarea de funcții SAS

a) Definirea problemei:

Se urmărește calcularea unor indicatori derivați care să reflecte eficiența financiară, precum venitul per oaspete sau creșterea logaritmică a veniturilor auxiliare.

b) Informații necesare pentru rezolvare:

- *Total_Revenue_EUR*
- *Number_of_Guests*
- *Spa_Revenue_EUR*

c) Metode de calcul, algoritmi, formule de calcul utilizate:

S-au folosit calcule directe și funcția *LOG()* aplicată în pasul *DATA*. Nu au fost necesare biblioteci externe.

d) Prezentarea rezultatelor:

S-au generat coloane suplimentare:

- *Revenue_per_Guest* – raport între venit total și număr de oaspeți
- *Log_Spa_Revenue* – transformare logaritmică a veniturilor Spa

e) Interpretarea economică a rezultatelor:

Acești indicatori oferă o imagine mai clară asupra eficienței financiare per oaspete și ajută la identificarea lunilor în care veniturile din servicii auxiliare (precum Spa-ul) au un potențial mai mare de creștere sau, dimpotrivă, necesită optimizare.

6. Combinarea seturilor de date prin proceduri *SAS* și *SQL*

a) Definirea problemei:

Pentru analiza integrată grupăm cele două seturi de date citite.

b) Informații necesare pentru rezolvare:

- Seturile *activity* și *reviews*
- Cheia comună: *Month_Year*

c) Metode de calcul, algoritmi, formule de calcul utilizate:

Au fost utilizate interogări SQL cu *JOIN* standard și filtrat (*INNER JOIN*, *WHERE*) în *PROC SQL*.

d) Prezentarea rezultatelor:

Două seturi de date rezultate:

- *combined_sql* – combinație completă
- *combined_low* – doar lunile cu scoruri < 9

e) Interpretarea economică a rezultatelor:

Această integrare permite corelarea directă între satisfacția clienților și performanța financiară. Se pot observa mai ușor lunile în care scorurile mai mici influențează negativ veniturile și invers, ajutând la luarea unor decizii strategice mai eficiente.

7. Utilizarea de masive

a) Definirea problemei:

Este nevoie de aplicarea acelorași transformări (ex. normalizare, conversie) asupra mai multor variabile numerice într-un mod eficient.

b) Informații necesare pentru rezolvare:

- *Total_Revenue_EUR, Spa_Revenue_EUR, Restaurant_Revenue_EUR*
- *Occupancy_Rate_Percent, Repeat_Guest_Rate*

c) Metode de calcul, algoritmi, formule de calcul utilizate:

Au fost definite *ARRAY*-uri și bucle *DO* pentru procesarea simultană a mai multor variabile în pasul *DATA*.

d) Prezentarea rezultatelor:

Seturi extinse cu valori normalizate (mii de EUR și zecimale pentru procente).

e) Interpretarea economică a rezultatelor:

Transformarea variabilelor într-un format standardizat (mii de euro, zecimale) permite o comparare mai ușoară între indicatori și ajută la interpretarea mai clară a evoluției financiare și a gradului de fidelizare a clienților.

8. Utilizarea de proceduri pentru raportare

a) Definirea problemei:

Se dorește identificarea și prezentarea cât mai clară a informațiilor importante pentru cei care iau decizii.

b) Informații necesare pentru rezolvare:

- *Average_Review_Score*
- *Number_of_Guests*

c) Metode de calcul, algoritmi, formule de calcul utilizate:

PROC PRINT cu filtre *WHERE* și selecție de variabile *VAR* pentru afișare relevantă.

d) Prezentarea rezultatelor:

Tabele simple cu lunile care îndeplinesc anumite condiții (ex: scor < 9, oaspeți > 1000).

Months with More Than 1000 Guests			
Obs	Month_Year	Number_of_Guests	Total_Revenue_EUR
2	February 2022	2500	120255.64
9	September 2022	2500	76174.72
16	April 2023	2500	151545.86
35	November 2024	2500	93346.89

e) Interpretarea economică a rezultatelor:

Rezultatele afișate sub formă de tabel ajută la luarea de decizii manageriale, oferind o imagine clară asupra lunilor cu activitate ridicată sau scoruri mai slabe, utile pentru acțiuni precum promovarea, organizarea echipei sau păstrarea clienților fideli.

9. Folosirea de proceduri statistice

a) Definirea problemei:

Este necesară obținerea unor indicatori statistici descriptivi pentru a înțelege comportamentul variabilelor cheie.

b) Informații necesare pentru rezolvare:

- *Total_Revenue_EUR, Occupancy_Rate_Percent*
- *Spa_Revenue_EUR, Restaurant_Revenue_EUR*

c) Metode de calcul, algoritmi, formule de calcul utilizate:

PROC MEANS cu opțiuni pentru medie, mediană, deviație standard, min, max.

d) Prezentarea rezultatelor:

Tabele cu valori statistice pentru fiecare variabilă analizată.

The MEANS Procedure				
Variable	Mean	Std Dev	Minimum	Maximum
Total_Revenue_EUR	106731.72	26521.07	70206.90	161634.21
Occupancy_Rate_Percent	62.9133333	19.2640528	31.6500000	90.4300000

Statistics for Spa and Restaurant Revenues			
The MEANS Procedure			
Variable	Mean	Median	Std Dev
Spa_Revenue_EUR	12326.31	12990.69	4391.33
Restaurant_Revenue_EUR	25535.94	28563.52	8788.08

e) Interpretarea economică a rezultatelor:

Prin indicatorii statistici obținuți, se pot observa mai ușor abaterile față de medie, diferențele între servicii și variabilitatea lunară a performanței. Aceste informații sunt utile pentru a înțelege stabilitatea afacerii, pentru a estima veniturile viitoare și pentru a fundamenta decizii legate de buget, prețuri sau investiții.

10.1. Generarea de grafice

a) Definirea problemei:

Se dorește vizualizarea evoluției în timp a principalelor variabile economice.

b) Informații necesare pentru rezolvare:


- *Month_Year, Total_Revenue_EUR, Occupancy_Rate_Percent*


c) Metode de calcul, algoritmi, formule de calcul utilizate:

PROC SGPLOT cu tip *SERIES* pentru grafice de linie.

d) Prezentarea rezultatelor:

Două grafice de linie separate pentru venituri și rata de ocupare.





e) Interpretarea economică a rezultatelor:

Graficele evidențiază fluctuațiile lunare ale veniturilor și ale gradului de ocupare. Aceste vizualizări ajută la identificarea unor tipare sezoniere, perioade de scădere sau creștere accentuată și oferă suport în planificarea strategică, optimizarea resurselor și adaptarea ofertelor în funcție de cerere.

10.2. Generarea de grafice – *Barplot*: numărul de oaspeți per an grupat pe sezoane

a) Definirea problemei:

Vizualizarea distribuției sezoniere a numărului de oaspeți pentru fiecare an.

b) Informații necesare pentru rezolvare:


Variabilele *Month_Year* și *Number_of_Guests*, cu derivare pentru *Season* și *Year*.

c) Metode de calcul, algoritmi, formule de calcul utilizate:

Prelucrare text în pasul *DATA* pentru extragerea lunii și anului, mapare lună → sezon cu *SELECT*, grafic de tip *VBAR* grupat.

d) Prezentarea rezultatelor:

Grafic bară grupat ce arată numărul total de oaspeți pe an, diferențiat pe sezoane.



e) Interpretarea economică a rezultatelor:

Graficul evidențiază perioadele din an cu cel mai mare număr de oaspeți, oferind o imagine clară asupra sezonality. Aceste informații sprijină organizarea eficientă a resurselor și adaptarea ofertelor în funcție de nivelul cererii din fiecare sezon.

11.1. SAS ML – Regresie liniară (Machine Learning de bază)

a) Definirea problemei:

Modelarea relației dintre venitul total și diverși factori predictor.

b) Informații necesare pentru rezolvare:

Date istorice despre venituri, ocupare, număr de oaspeți și venituri Spa.

c) Metode de calcul, algoritmi, formule de calcul utilizate:

PROC REG cu model de regresie liniară multiplă.

d) Prezentarea rezultatelor:

Coeficienți de regresie, valoarea R^2 și semnificația statistică a predictorilor.

Linear Regression: Revenue vs. Occupancy, Guests, and Spa Revenue

The REG Procedure
Model: MODEL1
Dependent Variable: Total_Revenue_EUR

Number of Observations Read	36
Number of Observations Used	32
Number of Observations with Missing Values	4


Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	3	2880408888	960136296	1.33	0.2838
Error	28	20180495678	720731989		
Corrected Total	31	23060904566			


Root MSE	26846	R-Square	0.1249
Dependent Mean	108836	Adj R-Sq	0.0311
Coeff Var	24.66684		

Parameter Estimates					
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	1	75721	22716	3.33	0.0024
Occupancy_Rate_Percent	1	41.97585	243.14262	0.17	0.8642
Number_of_Guests	1	4.30938	6.82604	0.63	0.5330

Multiple Linear Regression: Predicting Total Revenue

The REG Procedure
Model: MODEL1
Dependent Variable: Total_Revenue_EUR





e) Interpretarea economică a rezultatelor:

Ajută la înțelegerea influenței fiecărui factor asupra veniturilor și permite estimări predictive.

Modelul de regresie arată o legătură slabă între venitul total lunar și factorii analizați (rata de ocupare, numărul de oaspeți, veniturile Spa), explicând doar 12,5% din variația veniturilor ($R^2 = 0,125$). Modelul nu este semnificativ statistic ($p = 0,2838$), iar coeficienții pentru variabilele explicative nu au impact semnificativ. Singurul element relevant este interceptul, care sugerează un venit de bază independent de ceilalți factori.

11.2. SAS ML – Regresie liniară multiplă cu diagrame de diagnostic

a) Definirea problemei:

Modelarea complexă a veniturilor lunare în funcție de mai mulți predictorii economici pentru identificarea relațiilor multiple și eventuale anomalii.

b) Informații necesare pentru rezolvare:

Date istorice privind:



- Venitul total (*Total_Revenue_EUR*)
- Rata de ocupare (*Occupancy_Rate_Percent*)
- Numărul de oaspeți (*Number_of_Guests*)
- Venitul Spa și Restaurant (*Spa_Revenue_EUR*, *Restaurant_Revenue_EUR*)


c) Metode de calcul, algoritmi, formule de calcul utilizate:

PROC REG pentru regresie multiplă, cu grafice de diagnostic (*student.*predicted.*).

d) Prezentarea rezultatelor:

Coeficienți ai regresiei, valorile R^2 , grafice pentru detecția outlierilor și comportamentului reziduurilor.





e) Interpretarea economică a rezultatelor:

Oferă o bază solidă pentru luarea deciziilor strategice, identificând variabilele cu impact semnificativ și detectând posibile deviații de comportament.

Modelul de regresie încearcă să explice venitul total lunar pe baza ratei de ocupare, numărului de oaspeți și veniturilor din Spa și Restaurant. Capacitatea explicativă a modelului este modestă: doar 25,3% din variația veniturilor este explicată de acești factori ($R^2 = 0.2531$), iar semnificația globală a modelului este limitată ($p = 0.0859$).

Dintre variabilele analizate, doar veniturile din Spa și Restaurant au un impact semnificativ statistic asupra venitului total, cu coeficienți pozitivi. În schimb, rata de ocupare și numărul de oaspeți nu au o influență clară în acest model.

Concluzie

Proiectul realizat în SAS pentru analiza activității de la Casa Timiș a demonstrat importanța integrării și prelucrării corecte a datelor în vederea sprijinirii deciziilor strategice. Prin utilizarea unor metode variate – de la importul și transformarea datelor, până la vizualizări grafice și modele predictive – s-au obținut perspective utile asupra performanței lunare, sezonality, comportamentului clienților și factorilor care influențează veniturile. Chiar dacă modelele statistice au indicat o legătură modestă între unii indicatori și venitul total, procesul analitic oferă o bază solidă pentru optimizarea deciziilor în domenii precum marketing, alocarea resurselor și fidelizarea clienților. Acest tip de analiză contribuie la o înțelegere mai profundă a evoluției afacerii și la conturarea unor acțiuni concrete pentru îmbunătățirea rezultatelor la Casa Timiș.